

AI Voice Agent

Technical Exploration Plan

ภาพรวมและโครงสร้างระบบ

แผนสำรวจ **AI Voice Agent** เพื่อให้คุยโต้ตอบได้เร็ว จับจังหวะภาษาไทยได้เหมาะสม และทำงานกับระบบธุรกิจได้จริง

โจทย์ตั้งต้น จากบทสนทนาที่มีการรายงานเวลารอบประมาณ 5–10 วินาที ต้องวัดเส้นทางจริงก่อนระบุสาเหตุหรือเลือกเครื่องมือ

ภาพรวม Architecture



แผนภาพนี้เป็นโครงสร้างเชิงแนวคิด จุดตรวจเสียงและจับเทิร์นอาจอยู่ในบริการหรือเครื่องมือที่ใช้จริง จึงต้องตรวจตำแหน่งก่อนต่อระบบ

แบ่งความรับผิดชอบเป็น 3 ส่วน

ส่วนของระบบ	หน้าที่
Conversation Layer	คุยเร็ว ฟังเป็น จับจังหวะ และรับการพูดแทรก
Intelligence Layer	เข้าใจบริบท เลือกข้อมูลธุรกิจ และลดการตอบโดยไม่มีหลักฐาน
Action Layer	อ่านข้อมูล จองหรือเลื่อนนัด และอัปเดตระบบจริง

ลำดับสำรวจ: วัดระบบเดิม → ทดลองเสียงต่อเนื่อง → ทดสอบจังหวะสนทนา → เทียบเครื่องมือ → จัดข้อมูล → ทดลองเลื่อนนัด → พิจารณางานเบื้องหลัง

01-03 · หาดันเหตุความหน่วง

1. ตรวจสอบปัจจุบัน

- ☐ ระบุชื่อโมเดล Gemini รุ่น **API** และค่าตั้งที่ใช้จริง
- ☐ ตรวจสอบว่าเสียงเข้าและออกเป็น **Batch** หรือ **Streaming**
- ☐ ไหลเส้นทางโทรศัพท์ → รับเสียง → ตรวจจบคำพูด → โมเดล → เสียงตอบ → โทรศัพท์
- ☐ บันทึกเวลารอสะสม การพักข้อมูลเสียง และเครือข่าย แยกจากเวลาของโมเดล

2. ทดลอง Gemini Live API

สร้างการทดลองรับเสียงต่อเนื่องระหว่างลูกค้าพูด และส่งเสียงคำตอบกลับทันทีพร้อม ตรวจสอบการเรียกเครื่องมือและการตั้งค่าจบเทิร์นที่รุ่นใช้งานรองรับ

3. วัด Audio Pipeline แบบแยกช่วง

จุดเวลา	เหตุการณ์ที่ต้องบันทึก
T0	คำพูดสุดท้ายของผู้ใช้จบที่ต้นทาง
T1	เสียงส่วนสุดท้ายมาถึงระบบ
T2	ระบบตัดสินใจผู้ใช้จบเทิร์น
T3	ได้รับเสียงตอบชุดแรกจากโมเดล
T4	ผู้ใช้เริ่มได้ยินคำตอบทางโทรศัพท์

Latency ที่ผู้ใช้รู้สึก = $T4 - T0$ ส่วน **Time to First Audio** ของโมเดลในการทดลองนี้ = $T3 - T2$ ต้องรายงานทั้งสองค่า และระบุจุดวัดทุกครั้ง

ช่วงเวลา: รับเสียง $T1 - T0$ • ตัดสินจบเทิร์น $T2 - T1$ • รอเสียงโมเดล $T3 - T2$ • ส่งกลับและเล่นเสียง $T4 - T3$
หากวัดต่างเครื่อง ต้องทำให้นาฬิกาตรงกันหรือใช้การบันทึกเสียงต้นทางเพื่อเทียบเวลา

- ☐ เก็บหลายสายด้วยบทพูดเดิม ระบุสภาพเครือข่ายและจำนวนรอบ
- ☐ แยกรอบสนทนาปกติออกจากรอบที่เรียกเครื่องมือ
- ☐ ส่งมอบแผนภาพระบบจริง ตารางเวลาแต่ละช่วง และจุดที่หน่วงที่สุด

ตัวอย่างเดิม: $80 + 300 + 400 + 200 = 980$ มิลลิวินาที เป็นเพียงตัวอย่างการแจกแจงเวลา ไม่ใช่ผลวัดหรือเป้าหมายที่รับประกัน

04–05 · จังหวะภาษาไทยและการเลือกเครื่องมือ

4. ทดสอบ Turn Detection และ Backchannel

แยกคำรับฟังสั้น ๆ ออกจาก **Barge-in** โดยดูเจตนาและบริบท ไม่ใช่รายการคำอย่างเดียว เพราะ “ครับ” อาจเป็นได้ทั้งคำรับฟัง และคำตอบจบเทิร์น

กรณีทดสอบ	พฤติกรรมที่ต้องประเมิน
“ครับ / อืม / อ้อ” ระหว่าง AI พูด	ไม่หยุดคิดจังหวะเมื่อเป็นเพียงการรับฟัง
“ได้ยาก่อนครับ ขอเปลี่ยนวันนัด”	หยุดเสียงที่กำลังเล่นและฟังคำขอใหม่
เขียนคิดกลางประโยค / พูดซ้ำ	ไม่รับตอบก่อนผู้ใช้พูดจบ
เสียงรบกวน / พูดทับกัน	ไม่เข้าใจเสียงรบกวนเป็นคำขอ และกลับมาสนทนาต่อได้

- ☐ ตรวจ **VAD** และทดลอง **Semantic Turn Detection** หากรองรับ
- ☐ วัดจำนวนครั้งที่ตัดผู้ใช้ก่อนจบ หยุดคิดเพราะคำรับฟัง และพลาดคำพูดแทรก
- ☐ บันทึกเวลาตั้งแต่เริ่มพูดแทรกจนเสียง AI หยุดที่โทรศัพท์

5. เทียบ Pipecat กับ LiveKit Agents

สร้าง **Prototype** สองตัวด้วยเงื่อนไขเดียวกัน: โทรศัพท์ → เครื่องมือที่ทดลอง → Gemini → เครื่องมือธุรกิจหนึ่งตัว → เสียงตอบ

- ☐ ใช้โมเดล บทพูดภาษาไทย เครื่องมือธุรกิจ และเส้นทางโทรศัพท์เดียวกัน
- ☐ เทียบเวลาตอบ การพูดแทรก เสียงต่อเนื่อง และการต่อโทรศัพท์
- ☐ เทียบ **Tool Calling** หรือ **Function Calling** การติดตามข้อผิดพลาด และความยากในการพัฒนาต่อ
- ☐ ส่งมอบตารางผลทดลองพร้อมข้อแลกเปลี่ยนและเหตุผลเลือก

สมมติฐานจากแผนเดิม: สำนวความยืดหยุ่นในการจัดทางเดินเสียงของ Pipecat และเครื่องมือโครงสร้างพื้นฐานของ LiveKit Agents แล้วตัดสินใจจากผลทดลองจริงกับภาษาไทย


06–07 · ข้อมูลธุรกิจและงานแรกที่ทำได้จริง

6. แยกข้อมูลธุรกิจเป็น 3 ประเภท

ประเภท	สิ่งที่ควรรวอยู่ในส่วนนี้
System Prompt	บทบาท บุคลิก ขอบเขตงาน และกฎที่ต้องปฏิบัติ
RAG	คำถามที่พบบ่อย ข้อมูลบริการ ขั้นตอน และนโยบายที่ค้นอ้างอิงได้
เครื่องมือ / API ของระบบจริง	ตารางนัด สถานะลูกค้า CRM สินค้าคงเหลือ และข้อมูลที่เปลี่ยนแปลงตลอดเวลา

ตัวอย่าง: “มีบริการอะไรบ้าง” ใช้เอกสารความรู้ได้ ส่วน “พรุ่งนี้หมอ A ว่างกี่โมง” ต้องอ่านตารางจริง ห้ามให้ AI เดาเวลาว่าง

7. เริ่มจากงานเลื่อนนัดหนึ่งงาน



- ☐ ใช้ Tool Calling อ่านนัด ตรวจเวลาว่าง และแก้ไขนัดตามลำดับ
- ☐ ตรวจสอบยืนยันก่อนเปลี่ยนข้อมูล และไม่แจ้งว่าสำเร็จก่อนระบบตอบสำเร็จ
- ☐ ทดสอบเวลานัดเต็ม ระบบไม่ตอบ และคำขอซ้ำ โดยไม่สร้างรายการซ้ำ
- ☐ ส่งมอบตัวอย่างสนทนาที่จบงานได้ พร้อมผลจากระบบและกรณีล้มเหลว

ผลที่ต้องเห็น: AI สนทนาและทำงานหนึ่งเรื่องให้จบ โดยอ้างอิงข้อมูลจริงและบอกสถานะได้ตรงกับสิ่งที่เกิดขึ้น

08 · งานเบื้องหลังและรายการส่งมอบ

8. ค่อยเพิ่ม Agent ชั้นหลัง

เมื่อส่วนสนทนาเร็วและเสถียรแล้ว จึงประเมิน **Hermes** หรือเครื่องมือจัดการผู้ช่วยอื่นสำหรับงานซับซ้อน ยืนยันว่าเป็นโครงการและรุ่นใดก่อนนำมาทดลอง

เส้นทางจาก AI สนทนา	ใช้เมื่อ
RAG	ต้องค้นเอกสารประกอบคำตอบ
เครื่องมืออย่างง่าย	ต้องอ่านหรือเปลี่ยนข้อมูลในขั้นตอนสั้น ๆ
Agent / Worker	ต้องทำงานหลายขั้นกับ CRM / ERP / ปฏิทิน / ฐานข้อมูล

ไม่ควรบังคับให้ทุกช่วงพูดผ่านการวางแผนงานเบื้องหลัง ส่วนสนทนาต้องรับฟังและแจ้งสถานะได้ระหว่างที่งานซับซ้อนกำลังทำอยู่

รายการตรวจรับผลสำรวจ

- ☐ 01 ระบุโมเดล ช่องทางเชื่อมต่อ และรูปแบบส่งเสียงปัจจุบันครบ
- ☐ 02 แสดงการรับ-ส่งเสียงต่อเนื่องและเวลาจนผู้ใช้ได้ยินคำตอบ
- ☐ 03 มีแผนภาพระบบจริง จุดวัดเวลา และสาเหตุความหน่วงจากหลักฐาน
- ☐ 04 มีผลทดสอบคำรับฟัง การหยุดคิด และการพูดแทรกภาษาไทย
- ☐ 05 มีผลเปรียบเทียบ Pipecat กับ LiveKit Agents ภายใต้เงื่อนไขเดียวกัน
- ☐ 06 แยกคำสั่งหลัก เอกสารความรู้ และข้อมูลจากระบบจริงแล้ว
- ☐ 07 งานเลื่อนนัดผ่านทั้งกรณีสำเร็จและล้มเหลวที่กำหนด
- ☐ 08 มีเหตุผลว่าจะเพิ่มผู้ช่วยเบื้องหลังเมื่อใด และช่วยงานใด

จุดตัดสินใจก่อนเดินหน้าพัฒนา

เริ่มด้วยการวัดระบบเดิม จากนั้นให้ทีมกำหนดเกณฑ์เวลาตอบและคุณภาพภาษาไทยจากผลทดลอง เปรียบเทียบเครื่องมือหลังเงื่อนไขทดสอบเท่ากัน แล้วขยายความสามารถเมื่อการเลื่อนนัดทำงานได้ถูกต้อง

ทีม: เรียบเรียงจากบทสนทนา “Branch · ค่ายกันหนอย” หัวข้อแผนสำรวจ AI Voice Agent ทั้ง 8 ข้อ โดยเพิ่มรายการตรวจรับและนิยามจุดวัดเพื่อใช้งานได้ชัดเจน เอกสารนี้เป็นแผนทดลอง ไม่ใช่รายงานผลทดสอบผลิตภัณฑ์